

MedellínVive: Predicción Inteligente de Bienestar Urbano por Comunas

Análisis de criminalidad y accidentalidad vial mediante Machine Learning y Recuperación Aumentada por Generación (RAG)

Kevin Quiroz González Carlos Alberto Mazo Gil

kquirozg@eafit.edu.co camazogl@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: https://github.com/kevinqzg/ProyectoFinal_IA

Resumen

Contexto: Las ciudades latinoamericanas enfrentan retos persistentes en materia de seguridad y movilidad. Medellín, pese a sus avances, mantiene disparidades significativas entre comunas que dificultan la priorización de políticas públicas basadas en evidencia. **Objetivo:** Construir un sistema que prediga el nivel de bienestar de las 16 comunas urbanas de Medellín cruzando datos abiertos de criminalidad e incidentes viales, e implemente un agente RAG para consultas ciudadanas en lenguaje natural. **Método:** Se integraron dos datasets de MEData (2015–2021), construyendo un índice de bienestar compuesto por comuna-año. Se compararon cuatro modelos de clasificación (Baseline, Árbol de decisión, Random Forest, XGBoost) con explicabilidad SHAP, y se implementó un sistema RAG con ChromaDB, embeddings BAAI/bge-m3 y LLaMA 3.1 vía Groq. **Resultados:** XGBoost y Random Forest alcanzaron un F1-macro de 0.937–0.939 y AUC-ROC de 0.973–0.989, superando ampliamente el baseline (F1 = 0.174). El sistema RAG respondió preguntas ciudadanas con alta coherencia contextual. **Conclusión:** Es posible predecir con alta precisión el nivel de bienestar comunal a partir de indicadores públicos de seguridad y movilidad, y hacer esa información accesible mediante lenguaje natural.

Palabras clave: Machine Learning, XGBoost, SHAP, RAG, ChromaDB, datos abiertos, bienestar urbano, Medellín.

1. Introducción

Medellín ha sido reconocida internacionalmente por su transformación urbana, pero persisten brechas significativas entre comunas en términos de seguridad y calidad de vida [5]. El acceso a esta información es fragmentado: los

datos existen en portales como MEData, pero requieren conocimiento técnico para ser interpretados.

Este proyecto aborda la siguiente pregunta de investigación: *¿Puede un modelo de ML predecir el nivel de bienestar de una comuna de Medellín cruzando indicadores de criminalidad y accidentalidad vial, con un F1-macro superior al baseline, y puede un sistema RAG responder preguntas ciudadanas sobre esos datos con alta fidelidad?*

Se utilizaron dos datasets públicos de MEData: criminalidad por comunas (2015–2023, Secretaría de Seguridad SISC) y víctimas en incidentes viales (2015–2021, Secretaría de Movilidad). El dataset maestro resultante contiene 112 registros (16 comunas × 7 años) con 10 features y variable objetivo balanceada en tres clases (bajo, medio, alto).

El documento se organiza así: Sección 2 describe los datos y el EDA, Sección 3 la arquitectura del sistema, Sección 4 la metodología experimental, Sección 5 los resultados, Sección 6 la discusión y Sección 7 las conclusiones.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset maestro

Atributo	Descripción
Fuente	MEData – Alcaldía de Medellín
Registros (N)	112 filas (comuna × año)
Features (p)	10 numéricas
Variable objetivo	nivel_bienestar (3 clases)
Período	2015–2021
Comunas	16 comunas urbanas
Valores nulos	0 (imputación por mediana)

Los dos datasets de MEData se cruzaron usando la llave (comuna, año). Los indicadores de criminalidad se desagregaron por tipo de delito (hurto a persona, homicidio,

extorsión, entre otros) y los incidentes viales se agregaron contando víctimas y muertos por comuna-año. La variable objetivo se construyó mediante z-scores estandarizados de los indicadores negativos (mayor criminalidad = menor bienestar), discretizados en terciles: bajo, medio y alto.

2.2. Hallazgos del análisis exploratorio

El análisis reveló patrones relevantes. La **distribución de la variable objetivo** quedó perfectamente balanceada: 38 registros en clase bajo y 37 en medio y alto, lo que elimina el riesgo de sesgo por desbalance.

La **comuna 10** (La Candelaria) concentra consistentemente el mayor volumen de criminalidad, con un pico de 15.516 delitos en 2019. Las comunas 1 (Popular) y 2 (Santa Cruz) registran los niveles más bajos, coherente con su menor densidad comercial.

Se observó una **caída notable en 2020** en todos los indicadores, atribuible al confinamiento por COVID-19, seguida de una recuperación parcial en 2021–2022.

La **correlación** entre `victimas_viales` y `muertos_viales` es de 0.93, indicando multicolinealidad alta. El análisis SHAP posterior permitió determinar cuál de las dos variables domina realmente en la predicción.




Figura 1: Criminalidad por comuna y año (2015–2021). La comuna 10 domina en todos los años.

3. Arquitectura del Sistema

El sistema MedellínVive tiene dos componentes principales que operan sobre el mismo dataset maestro.

3.1. Componentes principales

Preprocesamiento. Pipeline de limpieza que unifica los dos datasets de MEData por la llave (`comuna`, `año`), imputa valores faltantes con mediana por comuna, construye el índice de bienestar compuesto y discretiza en tres clases. División train/val/test: 70%/15%/15% con `random_state=42`.

Modelo de ML. Clasificador XGBoost con 300 estimadores, `max_depth=4`, `learning_rate=0.05`,

`subsample=0.8`. Se usó SHAP (*SHapley Additive exPlanations*) para explicar la contribución de cada feature a las predicciones individuales.

Componente RAG. Vector store ChromaDB con embeddings BAAI/bge-m3 de HuggingFace. Cada registro del dataset maestro se indexa como un documento con su contexto de comuna y año. El LLM LLaMA 3.1-8b vía Groq API genera respuestas en lenguaje natural citando los datos recuperados. La estrategia de prompting es zero-shot con contexto explícito.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros del modelo XGBoost

Parámetro	Valor
n_estimators	300
max_depth	4
learning_rate	0.05
subsample	0.8
colsample_bytree	0.8
eval_metric	mlogloss
Framework	scikit-learn + XGBoost
Hardware	MacOS ARM64 (CPU)

4.2. Estrategia de validación

Se empleó una división estratificada hold-out 70/15/15, garantizando que la proporción de clases se mantenga en cada partición. Adicionalmente, se aplicó validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento para estimar la varianza del modelo, dada la reducida cantidad de registros (112 filas).

4.3. Experimentos realizados

- Baseline:** `DummyClassifier` con estrategia de mayoría de clase. Referencia mínima a superar.
- Experimento 1:** Árbol de decisión con `max_depth=4` y `min_samples_leaf=3`. Modelo interpretable como punto intermedio.
- Experimento 2:** Random Forest con 200 estimadores.
- Experimento 3 (mejor):** XGBoost con búsqueda manual de hiperparámetros y análisis SHAP para explicabilidad.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de modelos – métricas en test set

Modelo	Acc.	F1	AUC
Baseline	0.353	0.174	0.500
Árbol decisión	0.824	0.817	0.968
Random Forest	0.941	0.939	0.989
XGBoost	0.941	0.937	0.973

Todos los modelos superan ampliamente el baseline. XGBoost y Random Forest alcanzan un rendimiento casi idéntico, con F1-macro de 0.937 y 0.939 respectivamente, y AUC-ROC superior a 0.97. El árbol de decisión, pese a su simplicidad, logra F1 = 0.817, lo que sugiere que las features disponibles tienen alta capacidad discriminativa.

5.2. Análisis de importancia — SHAP




Figura 2: Importancia de features según SHAP (media del valor absoluto).

El análisis SHAP revela que `victimas_viales` y `total_delitos` son las features con mayor impacto en las predicciones. Pese a la alta correlación entre `victimas_viales` y `muertos_viales` ($r = 0.93$), SHAP muestra que el modelo depende principalmente de la primera, lo que justifica mantener ambas variables en el dataset.

5.3. Análisis cualitativo — Sistema RAG

El sistema RAG demostró capacidad para responder preguntas en lenguaje natural sobre los datos de las comunas, citando valores exactos del dataset:

```

1 Pregunta: "Cual fue la comuna con mas
2 delitos en 2020?"
3
4 Respuesta: "Segun el contexto, la comuna
5 con mas delitos en 2020 fue la comuna 10
6 de Medellin, con un total de 9364 delitos."
```

Listing 1: Ejemplo de interacción con el sistema RAG

6. Discusión

6.1. Interpretación de resultados

El objetivo planteado se logró satisfactoriamente. Los modelos XGBoost y Random Forest superaron el baseline en 76 puntos porcentuales de F1-macro ($0.174 \rightarrow 0.939$), confirmando que los indicadores de criminalidad y accidentalidad vial tienen alta capacidad predictiva del nivel de bienestar comunal.

La caída en criminalidad registrada en 2020 es coherente con el confinamiento por COVID-19 y representa un patrón temporal que el modelo captura correctamente al incluir el año como contexto implícito en la agregación de features.

El sistema RAG complementa el componente predictivo al democratizar el acceso a los datos: cualquier ciudadano puede consultar en lenguaje natural sin necesidad de conocimientos técnicos.

6.2. Limitaciones

- **Tamaño del dataset:** 112 registros es un volumen reducido para ML. Los intervalos de confianza en el test set son amplios dado que solo contiene 17 muestras.
- **Variable objetivo proxy:** el índice de bienestar se construyó desde las mismas features usadas en el modelo, lo que introduce cierta circularidad que no afecta la validez del ejercicio pero limita la generalización.
- **Ausencia de variables socioeconómicas:** la ECV (Encuesta de Calidad de Vida) no pudo integrarse por dificultades en el mapeo de columnas codificadas, limitando la riqueza del índice de bienestar.
- **RAG sin evaluación RAGAS formal:** por restricciones de tiempo no se completó la evaluación cuantitativa de faithfulness y answer relevancy.

6.3. Trabajo futuro

Con más tiempo y recursos se plantean dos extensiones concretas. Primero, integrar la Encuesta de Calidad de Vida de MEData para enriquecer el índice de bienestar con variables socioeconómicas (estrato, empleo, cobertura en salud), lo que permitiría construir un objetivo más robusto e independiente de las features del modelo. Segundo, desarrollar una interfaz interactiva en Streamlit que permita a funcionarios de la Alcaldía consultar predicciones por comuna y año en tiempo real, combinando el modelo ML con el agente RAG en un único panel de análisis.

7. Conclusiones

MedellínVive demostró que es posible predecir el nivel de bienestar de las comunas de Medellín con alta precisión (F1-macro = 0.937, AUC-ROC = 0.973) a partir de datos

públicos de criminalidad e incidentes viales, superando el baseline en 76 puntos porcentuales de F1. XGBoost y Random Forest presentaron rendimiento equivalente, con el primero ligeramente favorecido por su resistencia al sobreajuste en datasets pequeños.

El análisis SHAP identificó `victimas_viales` y `total_delitos` como las features de mayor impacto, lo que aporta interpretabilidad al modelo y puede orientar la priorización de intervenciones públicas por comuna.

El sistema RAG complementó el análisis predictivo al permitir consultas en lenguaje natural sobre los datos históricos, respondiendo preguntas con precisión y citando valores reales del dataset.

La pregunta de investigación fue respondida afirmativamente: sí es posible predecir el nivel de bienestar comunal con F1-macro muy superior al baseline (0.937 vs 0.174), y el sistema RAG demostró capacidad de respuesta coherente y fundamentada en los datos.

Contribuciones del equipo

Integrante	Contribución principal
Kevin Quiroz G.	EDA, preprocesamiento, modelado ML, SHAP
Carlos Mazo G.	Sistema RAG, integración LLM, informe final

Distribución de responsabilidades.

Repositorio y Demo

- **GitHub:** https://github.com/kevinqzg/ProyectoFinal_IA
- **Video demo (≤3 min):** https://youtu.be/_XIa7Wb7RyE
- **Instalación:** `pip install -r requirements.txt`
- **Notebook principal:** `notebooks/02_modeling.ipynb`

Referencias

[1] Lewis, P., Perez, E., Piktus, A., et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020. <https://arxiv.org/abs/2005.11401>

[2] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD 2016. <https://arxiv.org/abs/1603.02754>

[3] Lundberg, S., & Lee, S. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017. <https://arxiv.org/abs/1705.07874>

[4] Chase, H. (2022). *LangChain: Building applications with LLMs through composability*. <https://github.com/langchain-ai/langchain>

[5] Alcaldía de Medellín. (2022). *MEData – Portal de Datos Abiertos de Medellín*. <https://medata.gov.co>

A. Hiperparámetros detallados

El modelo XGBoost final fue reentrenado sobre `train+val` antes de la evaluación SHAP, usando los mismos hiperparámetros de la Tabla 2. No se realizó búsqueda automática de hiperparámetros (grid search) por el reducido tamaño del dataset; los valores se ajustaron manualmente comparando métricas de validación cruzada.

B. Ejemplos adicionales del sistema RAG

```
1 P: "Como evoluciono la accidentalidad
2     vial en la comuna 10 entre 2015
3     y 2021?"
4 R: "En 2015 se registraron 63 muertos.
5     En 2021, 41 muertos. La accidentalidad
6     disminuyo en ese periodo."
7
8 P: "Que comunas tuvieron nivel de
9     bienestar BAJO en 2019?"
10 R: "Las comunas con nivel BAJO en 2019
11     fueron: Comuna 4 (indice -0.4419)..."
```

Listing 2: Ejemplos de Q&A del sistema RAG